# SUBTEMA 1.1: Análisis estadístico numérico

El análisis exploratorio de datos permite ver el tamaño y las características de los datos. Si los datos son muy variables, todas nuestras suposiciones de normalidad ya no se aplican. O si los datos tienen muchos valores extremos, estos pueden dominar al resto de los valores normales y hacer que los modelos sean muy inexactos. Ahora veremos cómo realizar un análisis exploratorio de datos en pySpark.

Iniciamos con la estadística descriptiva. Ya has visto este tema en otros contextos, **por ejemplo** Tablau para visualización de datos, tal vez cuando aprendiste el lenguaje R o tal vez cuando aprendiste Python y Scikit-Learn. En este tema no vamos a repetir los conceptos, pero te diremos cómo hacerlo en pySpark.

Vamos a suponer que has instalado Spark en un cuaderno de Google Colab y que lo has detectado y que has iniciado una sesión Spark. Vamos a suponer también que has montado el sistema de archivos del Google Drive.

Ahora leamos el archivo de datos "***daily_weather*.*csv***".
NOTA: El código con comentarios (#...)  ponemos varias formas de llevar a cabo este lectura:

# Practica en Colab

```
path_csv="/content/daily_weather.csv"
df = sqlContext.read.csv(path_csv,header=True,inferSchema=True)
#df = spark.read.csv(path_csv,header=True,inferSchema=True).coalesce(2)
#df=spark.read.format("csv").option("header","true").option("inferSchem
a"
,"true").option("minPartitions",2).load(path_csv)
df.show(10)
```

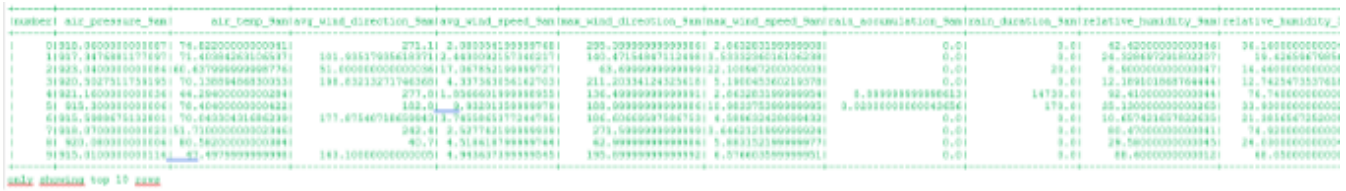

Recuerda que para ver las características de la base datos contenida en el dataframe puedes usar los siguientes comandos:

| Comando | Información |
|---|---|
| df.count() | Número de renglones |
| len(df.columns) | Número de columnas |
| df.columns | Nombres de columnas |
| df.printSchema() | Estructura con tipos de variables |

Para obtener una descripción estadística con número total de registros por variable, media, desviación estándar y valores máximos y mínimos se utiliza describe():

```
df.describe("number","air_pressure_9am","air_temp_9am","avg_wind_direct
ion_9am","avg_wind_speed_9am","max_wind_direction_9am").show()
#df.describe()
```

```
+-------+----------------+-----------------+------------------+
|summary|          number| air_pressure_9am|      air_temp_9am|
+-------+----------------+-----------------+------------------+
|  count|            1095|             1092|              1090|
```

```
|   mean|             547.0|918.8825513138094| 64.93300141287072|
| stddev|316.24357700987383|3.184161180386833|11.175514003175877|
|    min|                 0|907.9900000000024|36.752000000000685|
|    max|              1094|929.3200000000012| 98.90599999999992|
+-------+------------------+-----------------+------------------+
```

La información es suficientemente pequeña como para pasarlo al nodo coordinador (central) y usar Pandas para un desplegado más atractivo y comprensibles:

```
df.describe().toPandas().transpose()
```

| | 0 | 1 | 2 | 3 | 4 |
|---|---|---|---|---|---|
| summary | count | mean | stddev | min | max |
| number | 1095 | 547.0 | 316.24357700987383 | 0 | 1094 |
| air_pressure_9am | 1092 | 918.8825513138094 | 3.184161180386833 | 907.9900000000024 | 929.3200000000012 |
| air_temp_9am | 1090 | 64.93300141287072 | 11.175514003175877 | 36.752000000000685 | 98.90599999999992 |
| avg_wind_direction_9am | 1091 | 142.2355107005759 | 69.13785928889189 | 15.500000000000046 | 343.4 |
| avg_wind_speed_9am | 1092 | 5.508284242254930 | 4.552813465531718 5 | 0.6934513999997 4 | 23.554978199999763 |
| max_wind_direction_9am | 1092 | 148.9535179651692 3 | 67.23801294602953 | 28.899999999999 991 | 312.199999999999993 |
| max_wind_speed_9am | 1091 | 7.019513529175272 | 5.598209170780958 | 1.185578200000 0479 | 29.840779599999 96 |
| rain_accumulation_9am | 1089 | 0.2030789522521112 6 | 1.593952125357 4893 | 0.0 | 24.019999999999 07 |
| rain_duration_9am | 1092 | 294.1080522756142 | 1598.078778660 1481 | 0.0 | 17704.0 |
| relative_humidity_9am | 1095 | 34.24140205923536 | 25.47206680225 0055 | 6.090000000001 012 | 92.620000000002 |
| relative_humidity_3pm | 1095 | 35.34472714825898 | 22.52407945358 7273 | 5.300000000000 6855 | 92.250000000003 |

Nótese que en la columna “count” no todas las variables tienen la misma cantidad de valores, por lo que será necesario eliminar valores vacíos y nulos.

Para ver los cuantiles se usa el comando approxQuantile. Recuerde que los datos se encuentran distribuidos y la cantidad de ellos puede ser muy grande. Spark utiliza un método estadístico, por lo que los cuantiles son aproximados, no exactos. El siguiente ejemplo nos muestra los cuantiles de la variable **air_pressure_9am**:

```
quantiles_air_pressure_9am  =
df.approxQuantile("air_pressure_9am",[0.25, 0.5, 0.75], 0)
quantile_25 = quantiles_air_pressure_9am [0]
quantile_50 = quantiles_air_pressure_9am [1]
quantile_75 = quantiles_air_pressure_9am [2]
print('quantile_25: '+str(quantile_25))
print('quantile_50: '+str(quantile_50))
print('quantile_75: '+str(quantile_75))
```

```
quantile_25: 916.550000000009
quantile_50: 918.9020905167166
quantile_75: 921.1600000000036
```

El siguiente ejemplo muestra los cuantiles de todas las variables:

```
quantiles = df.approxQuantile(df.columns,[0.25, 0.5, 0.75], 0)
for i in range(len(df.columns)):
  print("Cuantiles " + str(df.columns[i]) + ": " + str(quantiles[0]))
```

```
Cuantiles number: [273.0, 547.0, 821.0]
Cuantiles air_pressure_9am: [273.0, 547.0, 821.0]
Cuantiles air_temp_9am: [273.0, 547.0, 821.0]
Cuantiles avg_wind_direction_9am: [273.0, 547.0, 821.0]
Cuantiles avg_wind_speed_9am: [273.0, 547.0, 821.0]
Cuantiles max_wind_direction_9am: [273.0, 547.0, 821.0]
Cuantiles max_wind_speed_9am: [273.0, 547.0, 821.0]
Cuantiles rain_accumulation_9am: [273.0, 547.0, 821.0]
Cuantiles rain_duration_9am: [273.0, 547.0, 821.0]
Cuantiles relative_humidity_9am: [273.0, 547.0, 821.0]
Cuantiles relative_humidity_3pm: [273.0, 547.0, 821.0]
```

Esta cantidad de información también es suficientemente pequeña para pasarla a Pandas como muestra el siguiente ejemplo:

```
pd.DataFrame(data=quantiles, index=df.columns,columns=[0.25, 0.5,
0.75])
```

| | 0.25 | 0.50 | 0.75 |
|---|---|---|---|
| number | 273.000000 | 547.000000 | 821.000000 |
| air_pressure_9am | 916.550000 | 918.902091 | 921.160000 |
| air_temp_9am | 57.272000 | 65.696000 | 73.454000 |
| avg_wind_direction_9am | 65.880616 | 166.000000 | 191.100000 |
| avg_wind_speed_9am | 2.248279 | 3.869906 | 7.337163 |
| max_wind_direction_9am | 76.456663 | 177.100000 | 201.200000 |
| max_wind_speed_9am | 3.064608 | 4.943637 | 8.970129 |
| rain_accumulation_9am | 0.000000 | 0.000000 | 0.000000 |
| rain_duration_9am | 0.000000 | 0.000000 | 0.000000 |
| relative_humidity_9am | 15.090000 | 23.179259 | 45.590000 |
| relative_humidity_3pm | 17.390000 | 24.380000 | 52.070000 |

Para encontrar las correlaciones se usa la función “Correlation” dentro MLIB Spark subpaquete pyspark.mk.stat. Sin embargo, requiere que se alimente una columna de tipo vector, por lo que necesario convertir las columnas del dataframe a vectores primero usando la función “VectorAssembler” y después de esto calcular las correlaciones. El resultado es un vector lineal, por lo que hay que cambiarlo a formato matrix. Sin embargo, la matrix de correlaciones no es muy grande, por lo que se pueden recolectar en el nodo central y luego manejarlo todo con Numpy y Pandas.

Ahora, la función “VectorAssembler” es muy importante porque se usa para los algoritmos de machine learning, tanto supervisada como la regresión y la clasificación, como no supervisada. Así es que es afortunado que podamos ver esta función tan importante en un contexto mas bien sencillo.

En el siguiente ejemplo se encuentran las correlaciones de Pearson de nuestro Spark Dataframe. Primero importamos nuestros paquetes y eliminamos valores nulos:

```
from pyspark.ml.stat import Correlation
from pyspark.ml.feature import VectorAssembler

df_dropped = df.na.drop()
df_dropped = df_dropped.drop("number")
df_columns2 = df_dropped.columns
```

Ahora ensamblamos el vector de columnas:

```
# convert to vector column first
vector_col = "corr_features"
assembler = VectorAssembler(inputCols=df_dropped.columns,
outputCol=vector_col)
df_vector = assembler.transform(df_dropped).select(vector_col)
```

Finalmente obtenemos la correlación entre variables:

```
r1 = Correlation.corr(df_vector, vector_col)
print("Pearson Corr
Matrix\n",r1.collect()[0]["pearson({})".format(vector_col)].values)
```

```
Pearson Corr Matrix
 [ 1.00e+00 -5.73e-02 -3.13e-01  2.36e-01 -2.87e-01  2.52e-01 -8.54e-02
 -1.00e-01 -4.31e-01 -4.80e-01 -5.73e-02  1.00e+00 -1.51e-02 -2.84e-01
 -7.95e-02 -2.82e-01 -1.99e-01 -2.59e-01 -5.82e-01 -4.91e-01 -3.13e-01
 -1.51e-02  1.00e+00 -4.41e-01  8.69e-01 -4.60e-01  1.18e-01  1.27e-01
  3.47e-01  3.85e-01  2.36e-01 -2.84e-01 -4.41e-01  1.00e+00 -3.64e-01
  9.95e-01  2.32e-03  1.21e-02 -9.55e-02 -1.54e-01 -2.87e-01 -7.95e-02
  8.69e-01 -3.64e-01  1.00e+00 -3.83e-01  9.10e-02  8.26e-02  3.69e-01
  4.06e-01  2.52e-01 -2.82e-01 -4.60e-01  9.95e-01 -3.83e-01  1.00e+00
 -3.34e-04  1.19e-02 -1.09e-01 -1.74e-01 -8.54e-02 -1.99e-01  1.18e-01
  2.32e-03  9.10e-02 -3.34e-04  1.00e+00  7.36e-01  2.29e-01  1.82e-01
 -1.00e-01 -2.59e-01  1.27e-01  1.21e-02  8.26e-02  1.19e-02  7.36e-01
  1.00e+00  3.05e-01  2.63e-01 -4.31e-01 -5.82e-01  3.47e-01 -9.55e-02
  3.69e-01 -1.09e-01  2.29e-01  3.05e-01  1.00e+00  8.81e-01 -4.80e-01
 -4.91e-01  3.85e-01 -1.54e-01  4.06e-01 -1.74e-01  1.82e-01  2.63e-01
  8.81e-01  1.00e+00]
```

Si cambiamos “pearson” por “spearman” se obtiene la correlación Spearman. El resultado es un vector unidimensional. Vamos a recolectarlo y luego pasarlo a una arreglo Numpy y luego un dataframe Pandas:

```
pearson_corr_arr =
np.matrix(r1.collect()[0]["pearson({})".format(vector_col)].values).res
hape(len(df.columns)-1, len(df.columns)-1)
pearson_corr_df = pd.DataFrame(data=pearson_corr_arr,
index=df_columns2,columns=df_columns2)
pearson_corr_df
```

| | air_pressure_9am | air_temp_9am | avg_wind_direction_9am | avg_wind_speed_9am | max_wind_direction_9am | max_wind_speed_9am | rain_accumulation_9am | rain_duration_9am | relative_humidity_9am | relative_humidity_3pm |
|---|---|---|---|---|---|---|---|---|---|---|
| air_pressure_9am | 1.000000 | -0.057329 | -0.313360 | 0.235826 | -0.287280 | 0.252479 | -0.085434 | -0.100485 | -0.431126 | -0.480117 |
| air_temp_9am | -0.057329 | 1.000000 | -0.015069 | -0.284327 | -0.079520 | -0.283025 | -0.199102 | -0.259103 | -0.582318 | -0.491068 |
| avg_wind_direction_9am | -0.313360 | -0.015069 | 1.000000 | -0.441441 | 0.868837 | -0.460122 | 0.117634 | 0.127367 | 0.346865 | 0.384885 |
| avg_wind_speed_9am | 0.235826 | -0.284327 | -0.441441 | 1.000000 | -0.364338 | 0.995412 | 0.002322 | 0.012057 | -0.095472 | -0.154422 |
| max_wind_direction_9am | -0.287280 | -0.079520 | 0.868837 | -0.364338 | 1.000000 | -0.383025 | 0.091003 | 0.082574 | 0.369500 | 0.405946 |
| max_wind_speed_9am | 0.252479 | -0.282483 | -0.460122 | 0.995412 | -0.383025 | 1.000000 | -0.000334 | 0.011890 | -0.108673 | -0.173720 |
| rain_accumulation_9am | -0.085434 | -0.199102 | 0.117634 | 0.002322 | 0.091003 | -0.000334 | 1.000000 | 0.735737 | 0.228951 | 0.181887 |
| rain_duration_9am | -0.100485 | -0.259103 | 0.127367 | 0.012057 | 0.082574 | 0.011890 | 0.735737 | 1.000000 | 0.304828 | 0.263283 |

| | | | | | | | | | | |
|---|---|---|---|---|---|---|---|---|---|---|
| relative_humidity_9am | -0.431126 | -0.582318 | 0.346865 | -0.095472 | 0.369500 | -0.108673 | 0.228951 | 0.304828 | 1.000000 | 0.881301 |
| relative_humidity_3pm | -0.480117 | -0.491068 | 0.384885 | -0.154422 | 0.405946 | -0.173720 | 0.181887 | 0.263283 | 0.881301 | 1.000000 |

Otra forma de hacerlo es con el paquete Statistics de MLIB. Primero eliminamos la columns "number" y luego los valores nulos:

```
from pyspark.mllib.stat import Statistics

df_features = df.drop("number")

df_features = df.select(df_features.columns).dropna()
```

Luego creamos una table RDD para almacenar las correlaciones:

```
rdd_table = df_features.rdd.map(lambda row: row[0:])
```

Finalmente llamamos "Statistics.corr" que nos generará una verdadera matriz:

```
corr_mat=Statistics.corr(rdd_table, method="pearson")
print(corr_mat)
```

```
[[ 1.00e+00 -5.73e-02 -3.13e-01  2.36e-01 -2.87e-01  2.52e-01 -8.54e-02
  -1.00e-01 -4.31e-01 -4.80e-01]
 [-5.73e-02  1.00e+00 -1.51e-02 -2.84e-01 -7.95e-02 -2.82e-01 -1.99e-01
  -2.59e-01 -5.82e-01 -4.91e-01]
 [-3.13e-01 -1.51e-02  1.00e+00 -4.41e-01  8.69e-01 -4.60e-01  1.18e-01
   1.27e-01  3.47e-01  3.85e-01]
 [ 2.36e-01 -2.84e-01 -4.41e-01  1.00e+00 -3.64e-01  9.95e-01  2.32e-03
   1.21e-02 -9.55e-02 -1.54e-01]
 [-2.87e-01 -7.95e-02  8.69e-01 -3.64e-01  1.00e+00 -3.83e-01  9.10e-02
   8.26e-02  3.69e-01  4.06e-01]
 [ 2.52e-01 -2.82e-01 -4.60e-01  9.95e-01 -3.83e-01  1.00e+00 -3.34e-04
   1.19e-02 -1.09e-01 -1.74e-01]
 [-8.54e-02 -1.99e-01  1.18e-01  2.32e-03  9.10e-02 -3.34e-04  1.00e+00
   7.36e-01  2.29e-01  1.82e-01]
 [-1.00e-01 -2.59e-01  1.27e-01  1.21e-02  8.26e-02  1.19e-02  7.36e-01
```

```
  1.00e+00   3.05e-01   2.63e-01]
[-4.31e-01 -5.82e-01   3.47e-01 -9.55e-02   3.69e-01 -1.09e-01   2.29e-01
  3.05e-01   1.00e+00   8.81e-01]
[-4.80e-01 -4.91e-01   3.85e-01 -1.54e-01   4.06e-01 -1.74e-01   1.82e-01
  2.63e-01   8.81e-01   1.00e+00]]
```

La cual también podemos pasar a un dataframe de Pandas para mejorar la visualización:

```
corr_mat_pd_pearson = pd.DataFrame(data=corr_mat,
index=df_features.columns,columns=df_features.columns)
corr_mat_pd_pearson
```

| | air_pressure_9am | air_temp_9am | avg_wind_direction_9am | avg_wind_speed_9am | max_wind_direction_9am | max_wind_speed_9am | rain_accumulation_9am | rain_duration_9am | relative_humidity_9am | relative_humidity_3pm |
|---|---|---|---|---|---|---|---|---|---|---|
| air_pressure_9am | 1.000000 | -0.057329 | -0.313360 | 0.235826 | -0.287280 | 0.252479 | -0.085434 | -0.100485 | -0.431126 | -0.480117 |
| air_temp_9am | -0.057329 | 1.000000 | -0.015069 | -0.284327 | -0.079520 | -0.283025 | -0.199102 | -0.259103 | -0.582318 | -0.491068 |
| avg_wind_direction_9am | -0.313360 | -0.015069 | 1.000000 | -0.441441 | 0.868837 | -0.460122 | 0.117634 | 0.127367 | 0.346865 | 0.384885 |
| avg_wind_speed_9am | 0.235826 | -0.284327 | -0.441441 | 1.000000 | -0.364338 | 0.995412 | 0.002322 | 0.012057 | -0.095472 | -0.154422 |
| max_wind_direction_9am | -0.287280 | -0.079520 | 0.868837 | -0.364338 | 1.000000 | -0.383025 | 0.091003 | 0.082574 | 0.369500 | 0.405946 |
| max_wind_speed_9am | 0.252479 | -0.282483 | -0.460122 | 0.995412 | -0.383025 | 1.000000 | -0.000334 | 0.011890 | -0.108673 | -0.173720 |
| rain_accumulation_9am | -0.085434 | -0.199102 | 0.117634 | 0.002322 | 0.091003 | -0.000334 | 1.000000 | 0.735737 | 0.228951 | 0.181887 |
| rain_duration_9am | -0.100485 | -0.259103 | 0.127367 | 0.012057 | 0.082574 | 0.011890 | 0.735737 | 1.000000 | 0.304828 | 0.263283 |

| | | | | | | | | | | |
|---|---|---|---|---|---|---|---|---|---|---|
| relative_humidity_9am | -0.431126 | -0.582318 | 0.346865 | -0.095472 | 0.369500 | -0.108673 | 0.228951 | 0.304828 | 1.000000 | 0.881301 |
| relative_humidity_3pm | -0.480117 | -0.491068 | 0.384885 | -0.154422 | 0.405946 | -0.173720 | 0.181887 | 0.263283 | 0.881301 | 1.000000 |

Lo mismo podemos hacer para obtener la correlación Spearman:

```
corr_mat_sp=Statistics.corr(rdd_table, method="spearman")
corr_mat_pd_sp = pd.DataFrame(data=corr_mat_sp,
index=df_features.columns,columns=df_features.columns)
corr_mat_pd_sp
```

| | air_pressure_9am | air_temp_9am | avg_wind_direction_9am | avg_wind_speed_9am | max_wind_direction_9am | max_wind_speed_9am | rain_accumulation_9am | rain_duration_9am | relative_humidity_9am | relative_humidity_3pm |
|---|---|---|---|---|---|---|---|---|---|---|
| air_pressure_9am | 1.000000 | -0.117418 | -0.279479 | 0.232753 | -0.243158 | 0.248009 | -0.063062 | 0.000697 | -0.472377 | -0.527897 |
| air_temp_9am | -0.117418 | 1.000000 | 0.021986 | -0.360481 | -0.040398 | -0.364843 | -0.227157 | -0.286164 | -0.424956 | -0.359926 |
| avg_wind_direction_9am | -0.279479 | 0.021986 | 1.000000 | -0.377934 | 0.859601 | -0.392063 | 0.142616 | 0.039965 | 0.335965 | 0.408805 |
| avg_wind_speed_9am | 0.232753 | -0.360481 | -0.377934 | 1.000000 | -0.299334 | 0.993435 | 0.082594 | 0.210421 | -0.105392 | -0.205306 |
| max_wind_direction_9am | -0.243158 | -0.040398 | 0.859601 | -0.299334 | 1.000000 | -0.309779 | 0.129086 | 0.043627 | 0.336457 | 0.394171 |
| max_wind_speed_9am | 0.248009 | -0.364843 | -0.392063 | 0.993435 | -0.309779 | 1.000000 | 0.080661 | 0.212161 | -0.112784 | -0.218481 |

| | | | | | | | | | | |
|---|---|---|---|---|---|---|---|---|---|---|
| rain_accumulation_9am | -0.063062 | -0.227157 | 0.142616 | 0.082594 | 0.129086 | 0.080661 | 1.000000 | 0.846628 | 0.286516 | 0.238172 |
| rain_duration_9am | 0.000697 | -0.286164 | 0.039965 | 0.210421 | 0.043627 | 0.212161 | 0.846628 | 1.000000 | 0.206381 | 0.150008 |
| relative_humidity_9am | -0.472377 | -0.424956 | 0.335965 | -0.105392 | 0.336457 | -0.112784 | 0.286516 | 0.206381 | 1.000000 | 0.866784 |
| relative_humidity_3pm | -0.527897 | -0.359926 | 0.408805 | -0.205306 | 0.394171 | -0.218481 | 0.238172 | 0.150008 | 0.866784 | 1.000000 |

Para visualizar las correlaciones correctamente podemos usar imshow de plotly.express que mostrará las correlaciones como un mapa de calor, el paquete seaborn que también usará colores o corrplot del paquete heatmapz que creará un mapa de color más fácil de leer.

Usando imshow y el arreglo de correlaciones:

```
import plotly.express as px

fig = px.imshow(pearson_corr_arr)
fig.show()
```

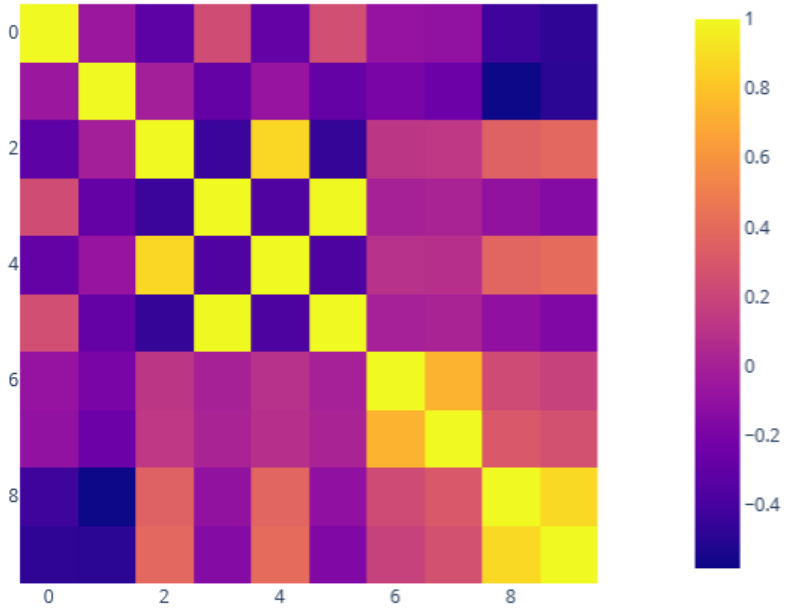


Nótese cómo es posible ver correlaciones significativas entre varias variables (pintadas de amarillo y naranja).

Ahora usando seaborn y el dataframe de correlaciones en vez del arreglo:

```
import seaborn as sns
sns.set(color_codes=True, font_scale=1.0)
from matplotlib import pyplot as plt

#Establecer el tamaño de la figura
plt.figure(figsize=(10,10))

ax = sns.heatmap(
    pearson_corr_df,
    vmin=-1, vmax=1, center=0,
    cmap=sns.diverging_palette(20, 220, n=200),
    square=True
)

#La barra de anotación
ax.set_xticklabels(
    ax.get_xticklabels(),
    rotation=45,
    horizontalalignment='right'
);
```

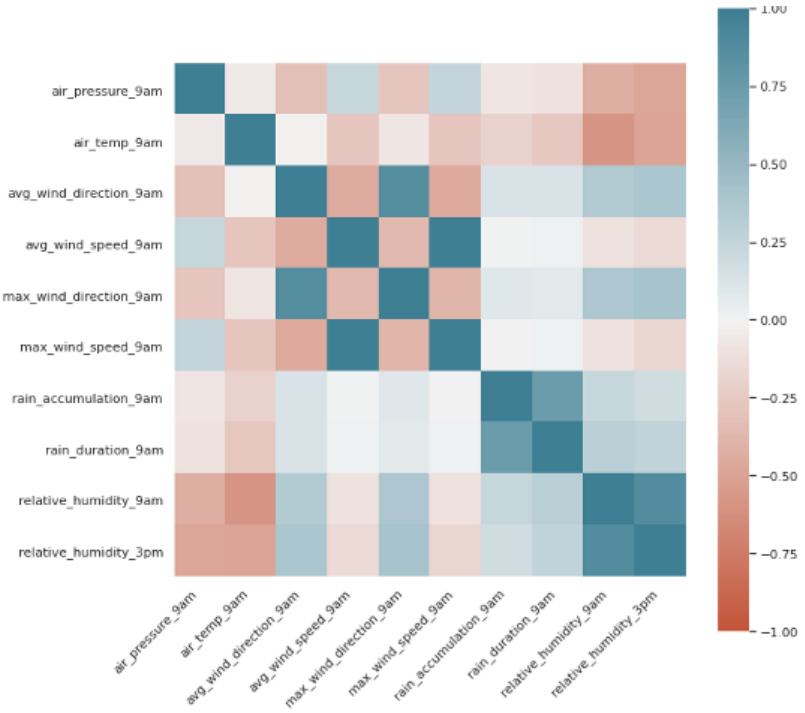


Y ahora usando el paquete corrplot de heatmapz (debemos instalar hetmapz):

```
!pip install heatmapz
```

**Ejemplo con el paquete heatmapz**

```
from heatmap import corrplot

plt.figure(figsize=(8, 8))
corrplot(pearson_corr_df ,size_scale=300);
```

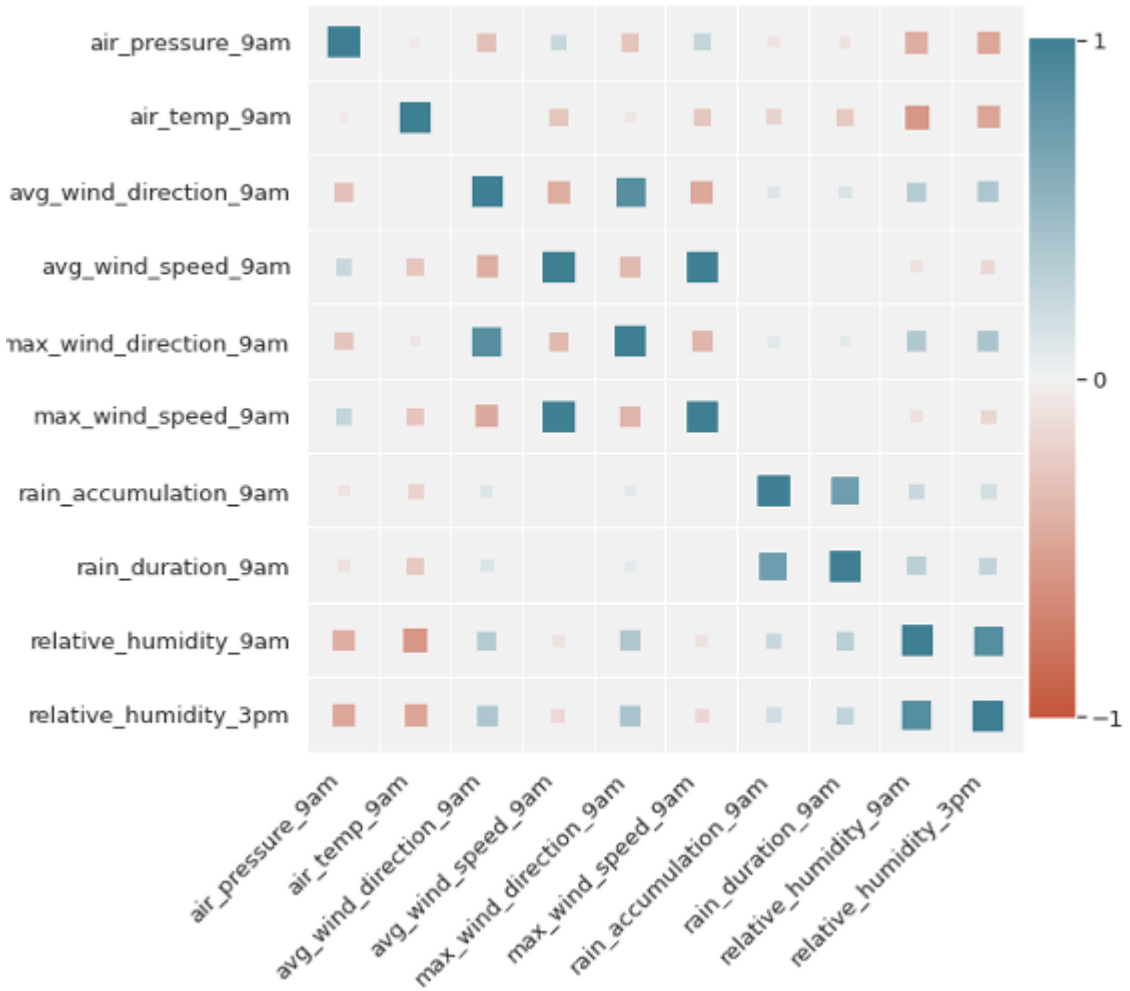
air_pressure_9am
air_temp_9am
avg_wind_direction_9am
avg_wind_speed_9am
max_wind_direction_9am
max_wind_speed_9am
rain_accumulation_9am
rain_duration_9am
relative_humidity_9am
relative_humidity_3pm
1
0
−1